Национальный исследовательский университет ИТМО
Факультет информационных технологий и программирования
Прикладная математика и информатика

Методы оптимизации

Отчет по лабораторной работе №2

Работу выполнили:

Коротков Арсентий M32351

Рябов Вадим M32351

Хайруллин Александр M32351

Преподаватель:

Ким Станислав Евгеньевич

г. Санкт-Петербург

2023 г.

Задание №1	3
Задание №2	7
Задание №3	9
Задание №4	12
Задание №5	16
Задание №6	17

Задание №1

Если минимизируемая функция имеет вид: $f = \sum_{i=1}^{n} f_i$, то для ее минимизации можно воспользоваться стохастическим градиентным спуском, основная идея которого заключается в том, что мы будем вычислять градиент лишь в одной из n компонент в каком-то случайном порядке. Это увеличит количество шагов, но уменьшит ресурсы, тратящиеся на вычисление одного шага, так как градиент берется лишь в одной компоненте.

Чтобы гарантированно посчитать градиент для всех компонент из суммы, можно считать его последовательно. С целью нахождения оптимального потребления ресурсов и числа шагов, возможно изменить данный алгоритм, введя такое понятие как батч, который отвечает за то, на скольких компонентах мы берем градиент за одну итерацию.

Примеры решения линейной регрессии с разными размерами батча:

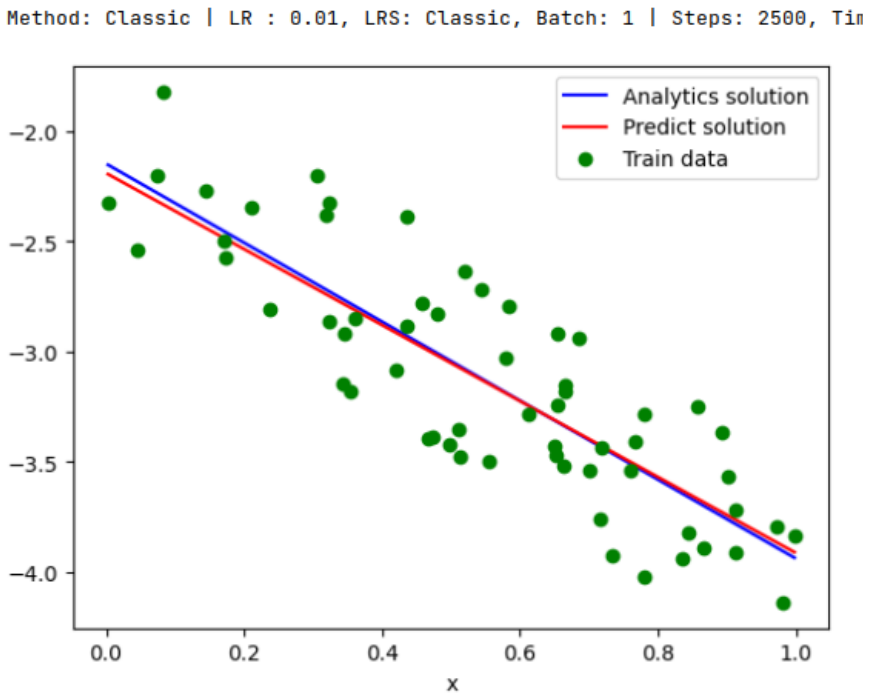

```
Method: Classic | LR : 0.01, LRS: Classic, Batch: 2 | Steps: 2500, T:
```

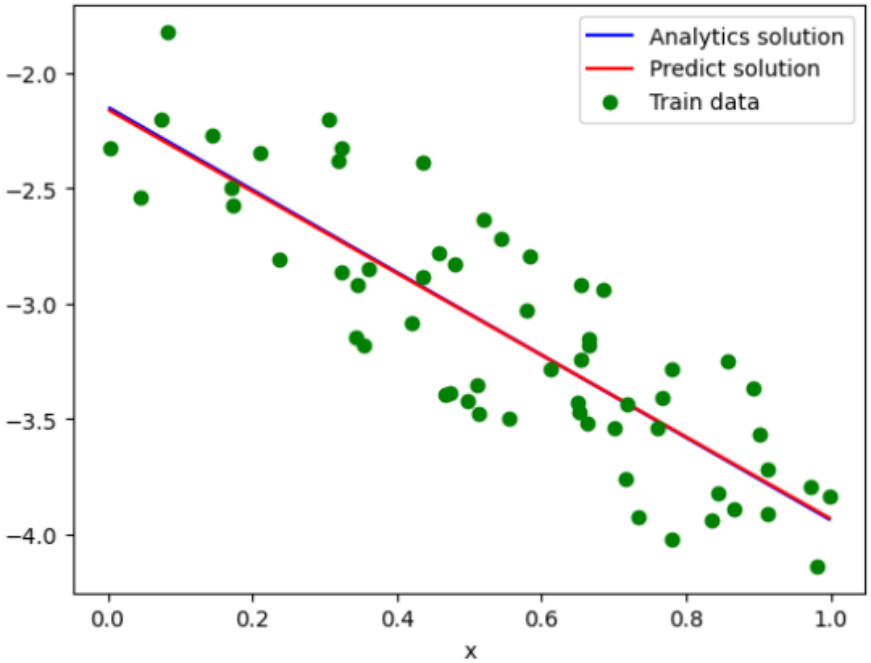


```
Method: Classic | LR : 0.01, LRS: Classic, Batch: 5 | Steps: 2500, T
```

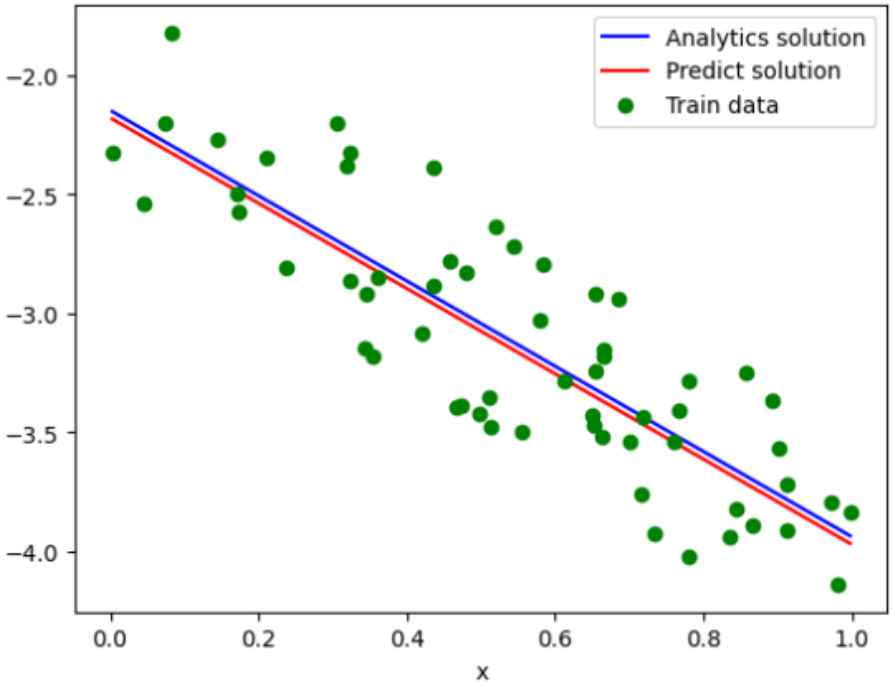

```
Method: Classic | LR : 0.01, LRS: Classic, Batch: 10 | Steps: 2500,
```

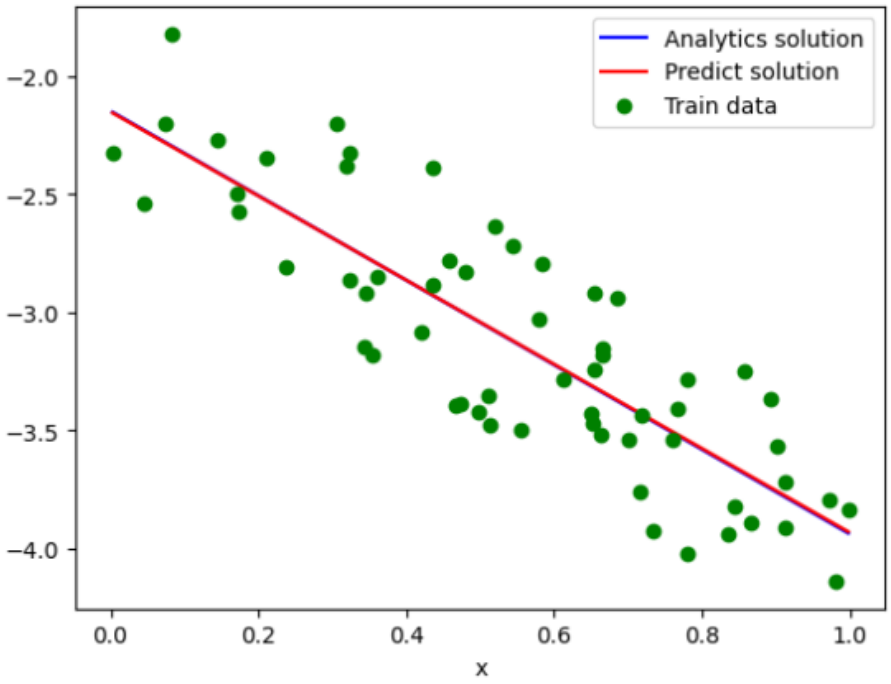


```
Method: Classic | LR : 0.01, LRS: Classic, Batch: 20 | Steps: 2500,
```

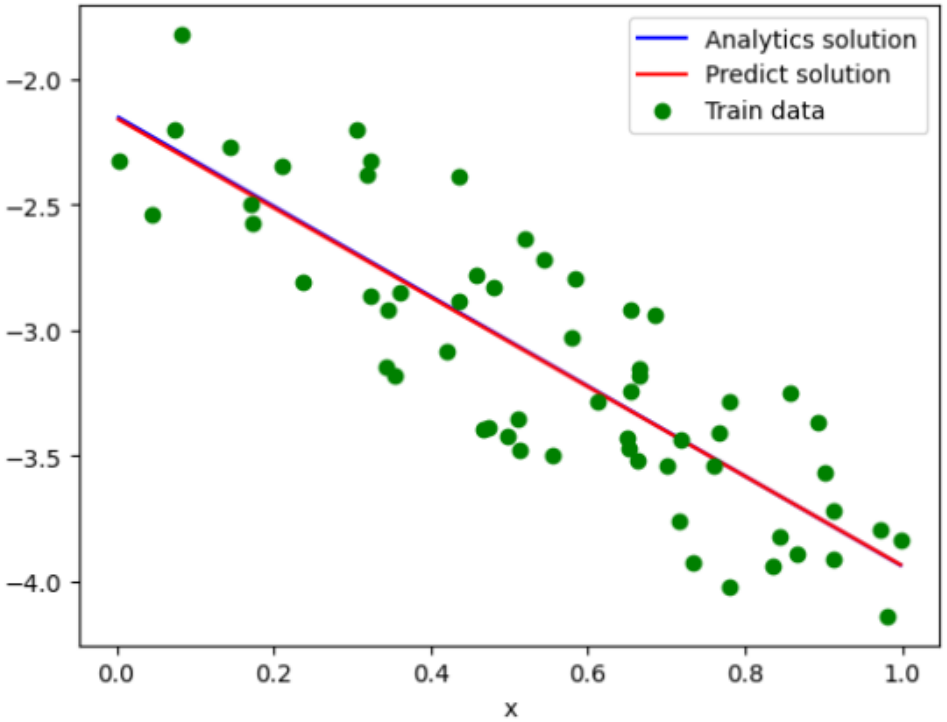

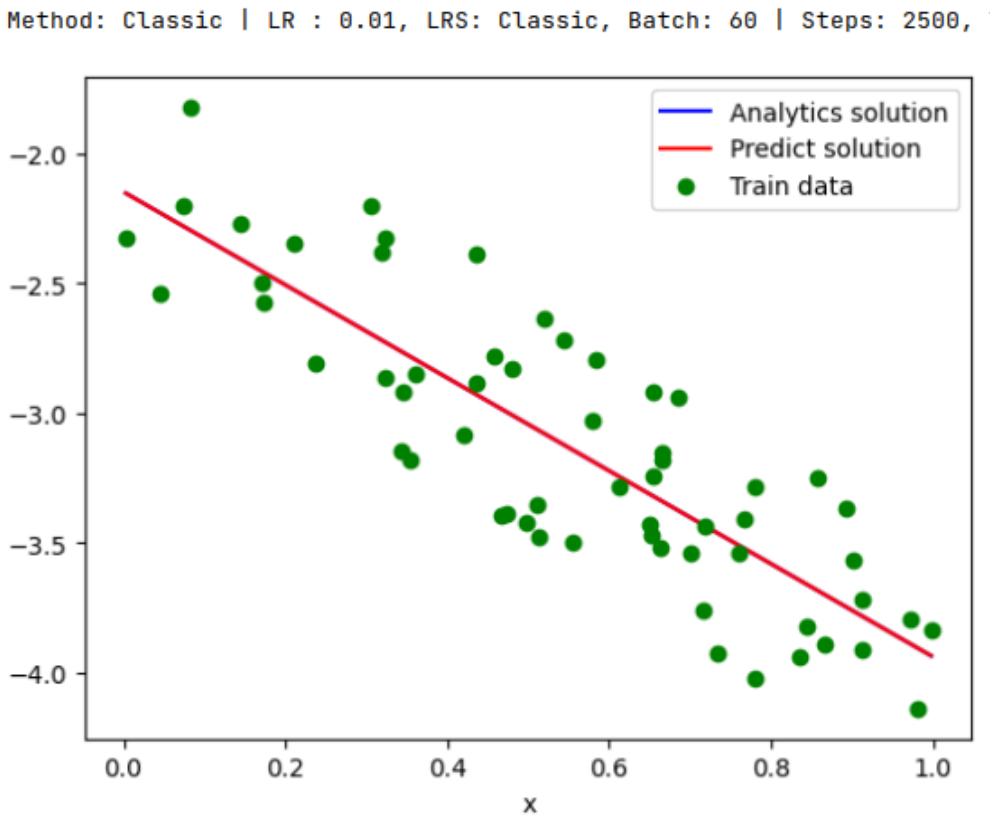

График зависимости относительной погрешности от размера батча.

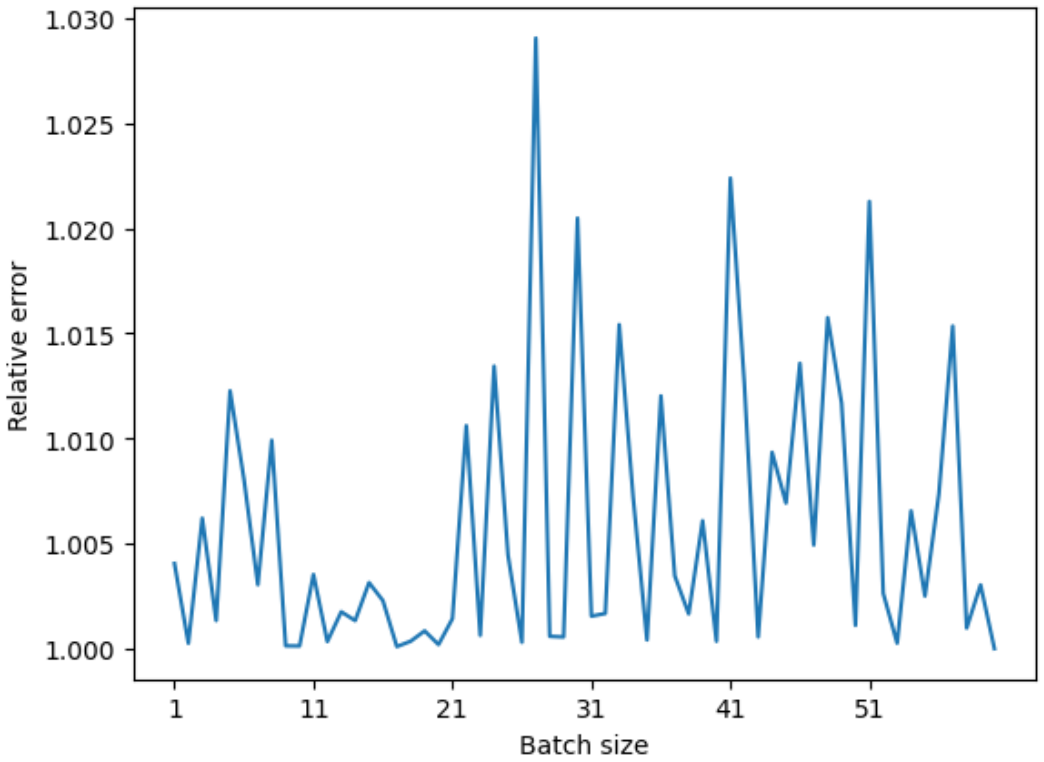

Задание №2

Были подобраны функции изменения шага:

Ступенчатая функция изменения шага	Экспоненциальная функция изменения шага
$lr = lr_0 - decay * \left[\frac{epoch}{frequency}\right]$	$lr = lr_0 * decay^{\left[\frac{epoch}{frequency}\right]}$

lr_0 - значение шага до изменения,

$decay$ - константа, характеризующая скорость уменьшения шага,

$epoch$ - суммарное число эпох ($(batch / n)$ * число итераций),

$frequency$ - частота обновления шага.

Примеры решения линейной регрессии с разными lrs:

Classic	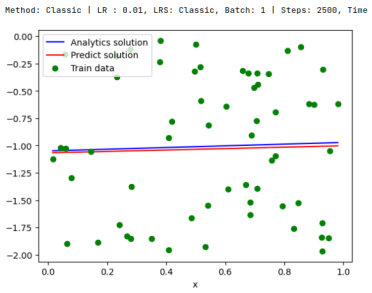	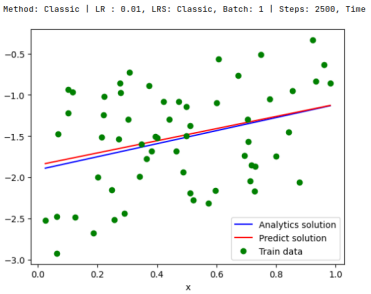	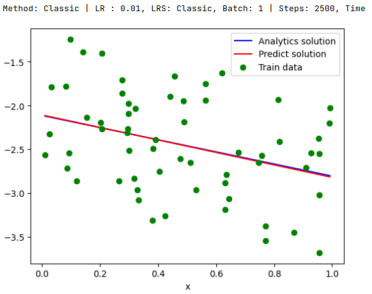

Stepwise	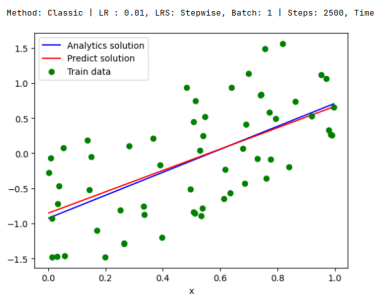	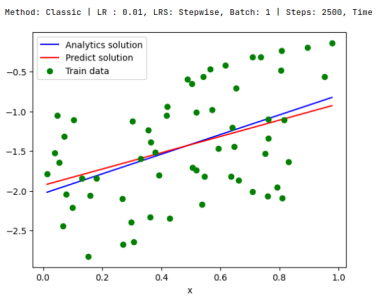	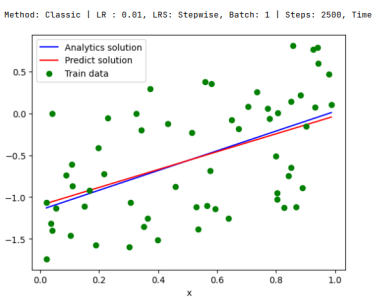
Exponential	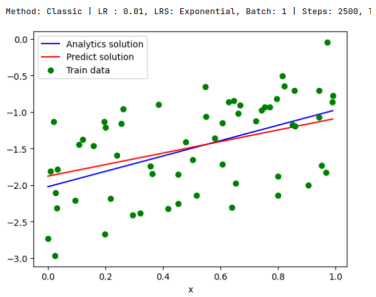	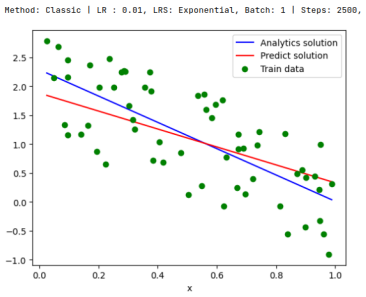	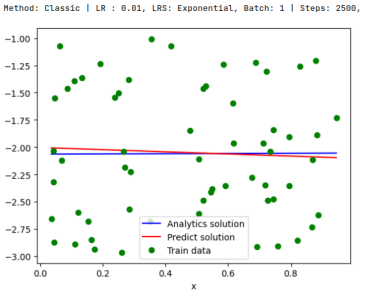

Задание №3

Модификации стохастического градиентного спуска.

$\supset g = \sum_j \nabla f_j$

Название	Формулы	Принцип работы
SGD	$w_{k+1} = w_k - \alpha g(x_k)$	Описание в теоретической сноске задания №1
Momentum	Классический вид: $v_{k+1} = \gamma v_k + (1 - \gamma) g(x_k)$ $w_{k+1} = w_k - \alpha v_{k+1}$ Альтернативный: $v_{k+1} = \gamma_k v_k - \alpha_k g(x_k)$ $w_{k+1} = w_k + v_{k+1}$	Смысл работы данной модификации проще понять, проведя аналогию с инерцией в реальной жизни. Некоторый объект, имея накопленный импульс и двигаясь по какой-то местности по инерции, не остановит свое движение из-за небольших неровностей на маршруте его траектории.
Nesterov	Классический вид: $v_{k+1} = \gamma v_k + (1 - \gamma) g(w_k - \alpha\gamma v_k)$ $w_{k+1} = w_k - \alpha v_{k+1}$ Альтернативный: $v_{k+1} = \gamma_k v_k - \alpha_k g(w_k + \gamma_k v_k)$ $w_{k+1} = w_k + v_{k+1}$	Алгоритм Нестерова улучшает моментум, считая градиент не в текущей точке, а в точке, где бы мы оказались, следуя мы импульсу нашей инерции. С помощью этого, наши колебания в направлении движения уменьшатся. В мире выпуклых функций алгоритм считается неулучшаемым.

Adagrad	$G_{k+1} = G_k + (g(w_k))^2$ $w_{k+1} = w_k - \frac{\alpha}{\sqrt{G_{k+1}+\varepsilon}} g(w_k)$	АдаГрад предполагает динамически подбирать размер шага для каждой константы по отдельности. Однако, нам нельзя слишком уменьшать размер шага, потому что выйди мы на плато, мы рискуем там и застрять. Потому такие девиации мы стараемся компенсировать.
RMSProp	$G_{k+1} = \gamma G_k + (1 - \gamma)(g(w_k))^2$ $w_{k+1} = w_k - \frac{\alpha}{\sqrt{G_{k+1}+\varepsilon}} g(w_k)$	Берется предыдущий алгоритм, однако нормы градиентов не просто складываются, но усредняются в скользящем режиме. Данные манипуляции позволяют замедлить уменьшение размера шага и всё ещё учитывать историю градиентов.
Adam	$v_{k+1} = \beta_1 v_k + (1 - \beta_1) g(w_k)$ $G_{k+1} = \beta_2 G_k + (1 - \beta_2)(g(w_k))^2$ $w_{k+1} = w_k - \frac{\alpha}{\sqrt{G_{k+1}+\varepsilon}} v_{k+1}$	Данный алгоритм объединяет в себе идеи двух основных идей, описываемых в алгоритмах выше (Adam ≡ Adaptive Momentum)

Также можно ввести коррекцию:

$$\tilde{v}_{k+1} = \frac{v_{k+1}}{1-\beta_1^{k+1}}$$

$$\tilde{G}_{k+1} = \frac{G_{k+1}}{1-\beta_2^{k+1}}$$

И подставлять в рекуррентную формулу для весов скорректированные величины соответственно. Так как $G_1 = v_1 = 0$, то параметры без коррекции будут слишком сильно от g_1, соответственно коррекция решает

эту проблему. Без коррекции же значения нормализуются сами собой через некоторое количество итераций.

Примеры решения линейной регрессии с разными модификациями:

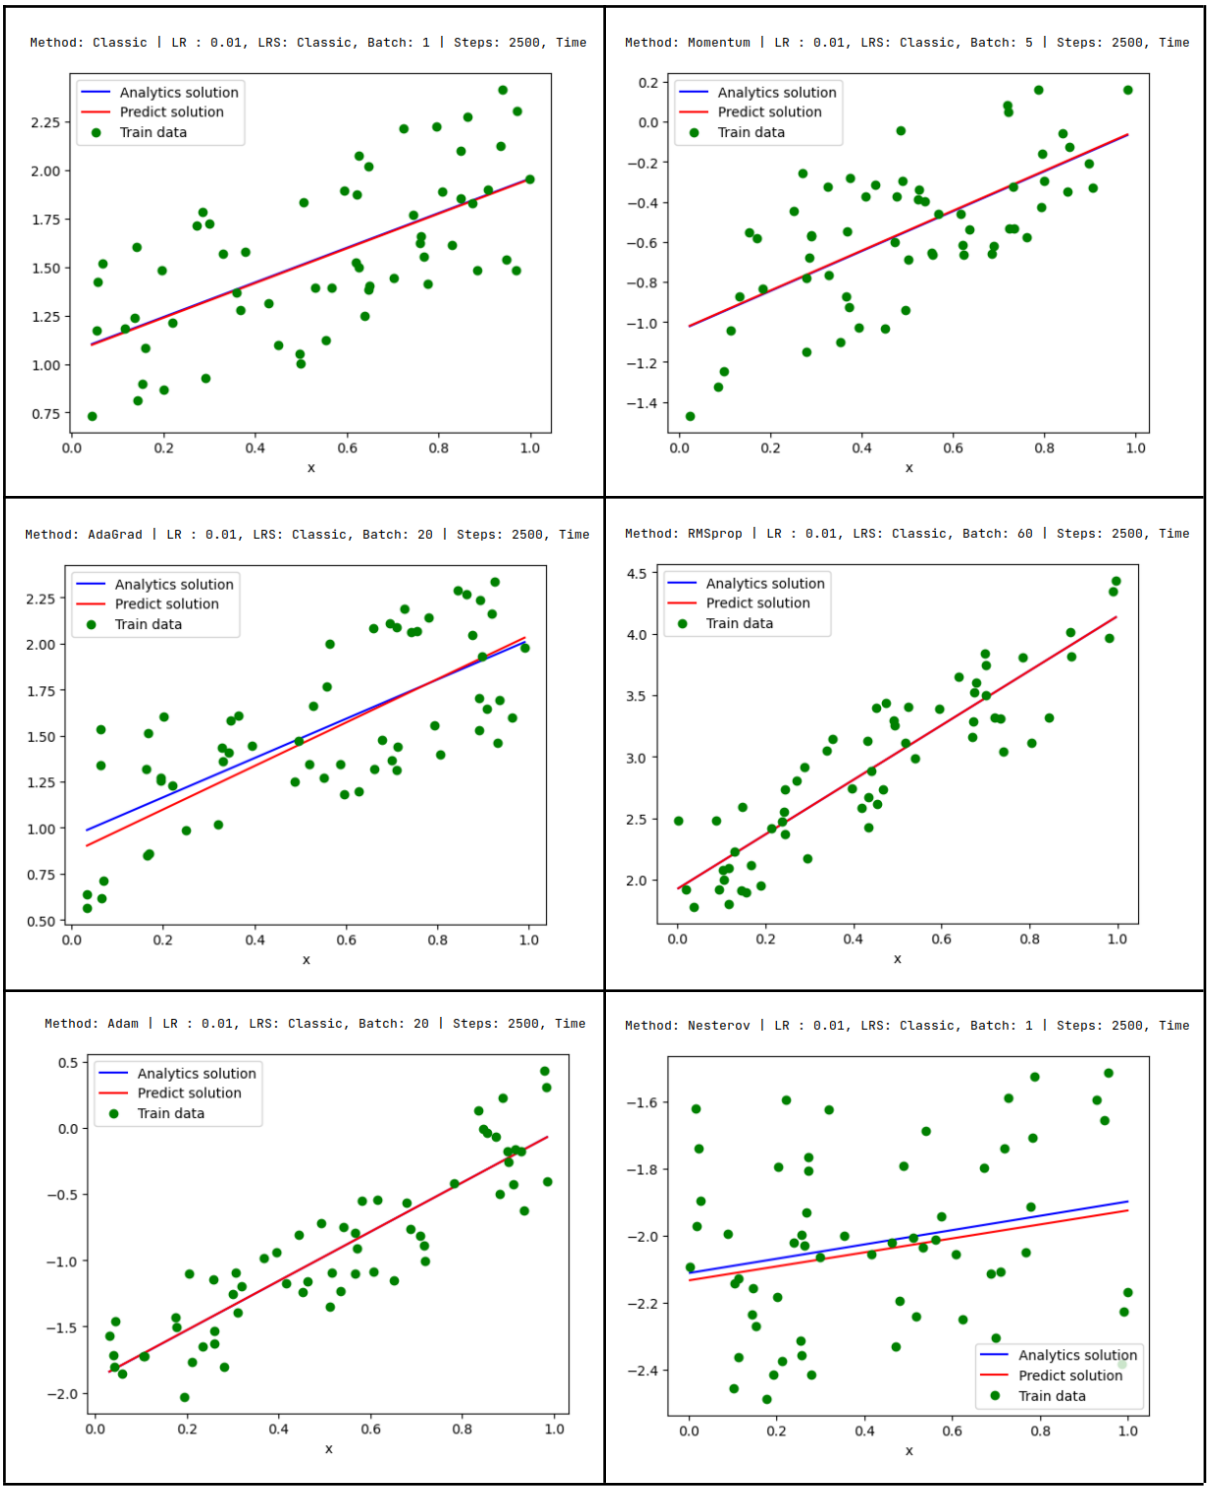

Задание №4

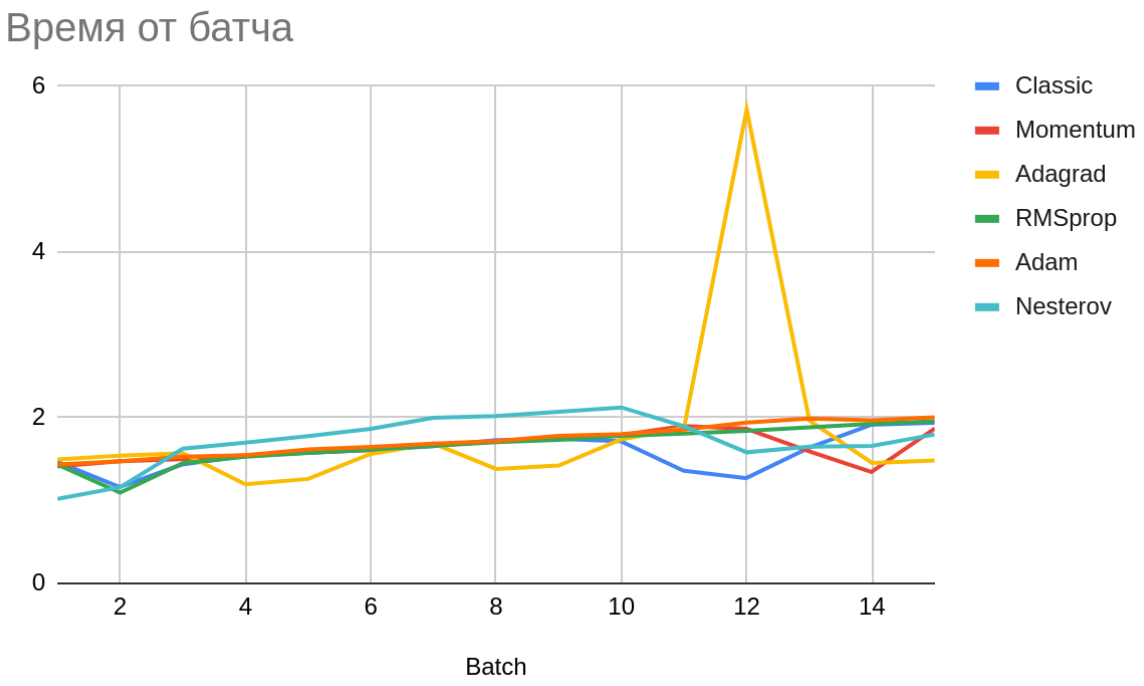
Время от батча
6
4
2
0
2
4
6
8
10
12
14
Batch
Classic
Momentum
Adagrad
RMSprop
Adam
Nesterov

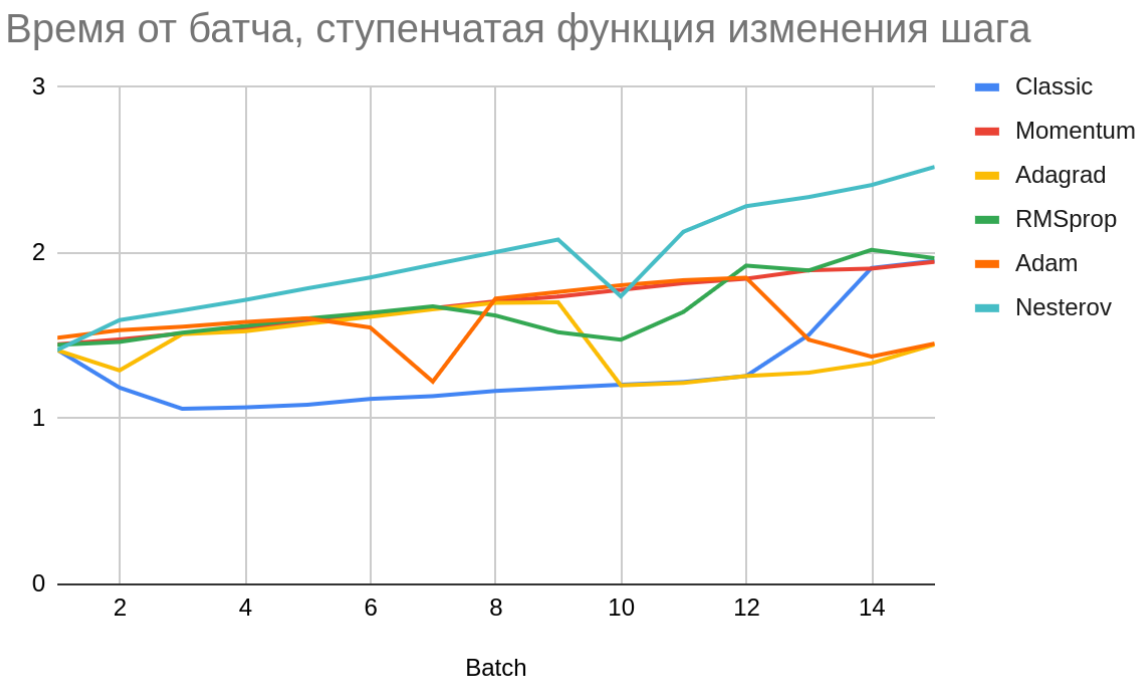
Время от батча, ступенчатая функция изменения шага
3
2
1
0
2
4
6
8
10
12
14
Batch
Classic
Momentum
Adagrad
RMSprop
Adam
Nesterov

Время от батча, экспоненциальная функция изменения шага

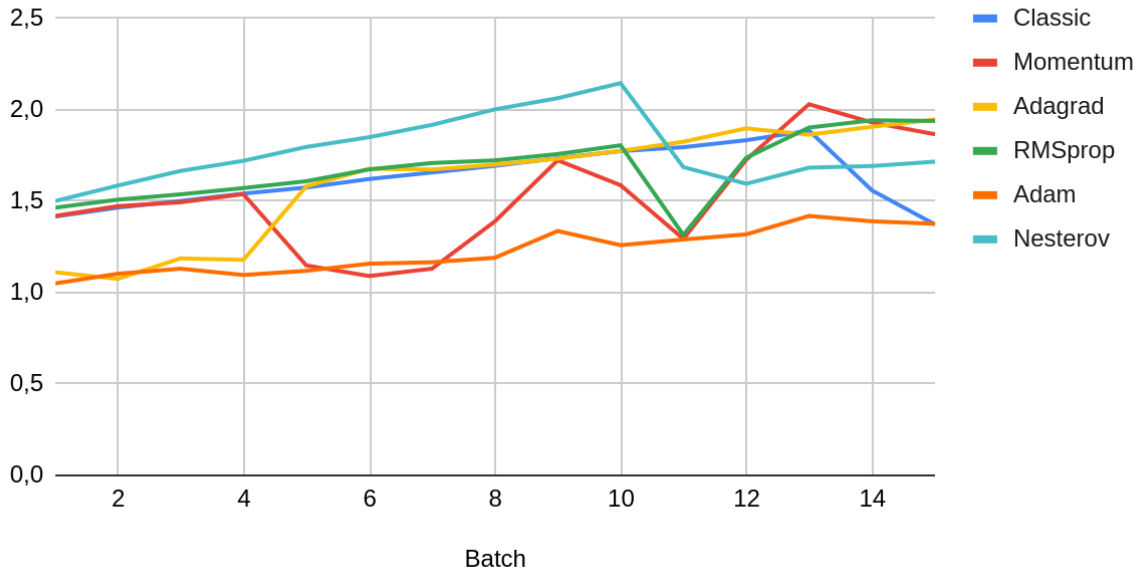

Отклонение от батча

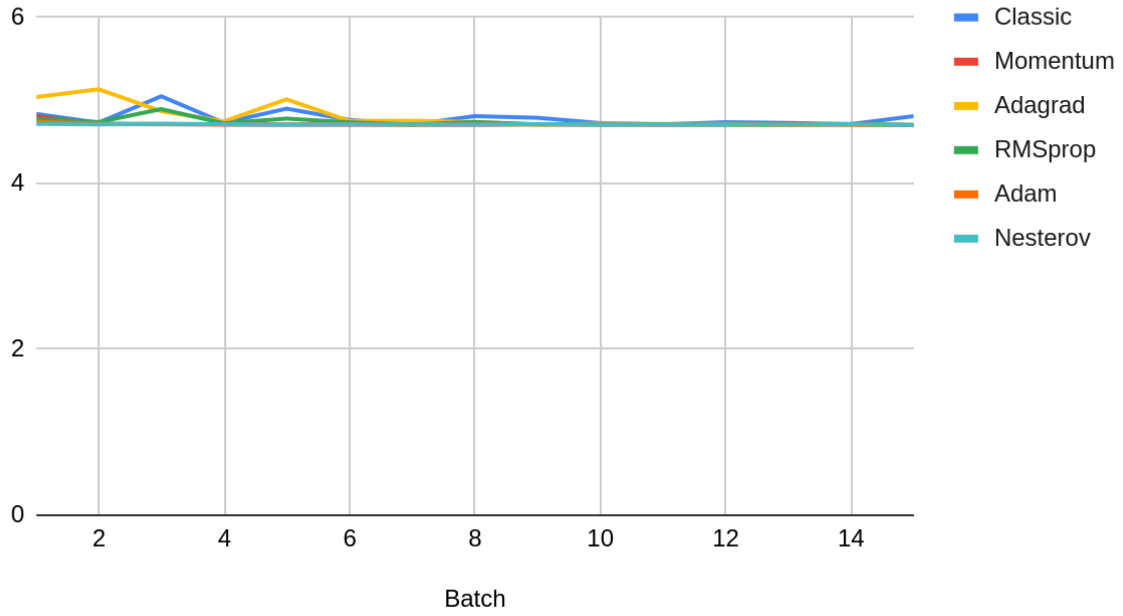

Отклонение от батча, ступенчатая функция изменения шага

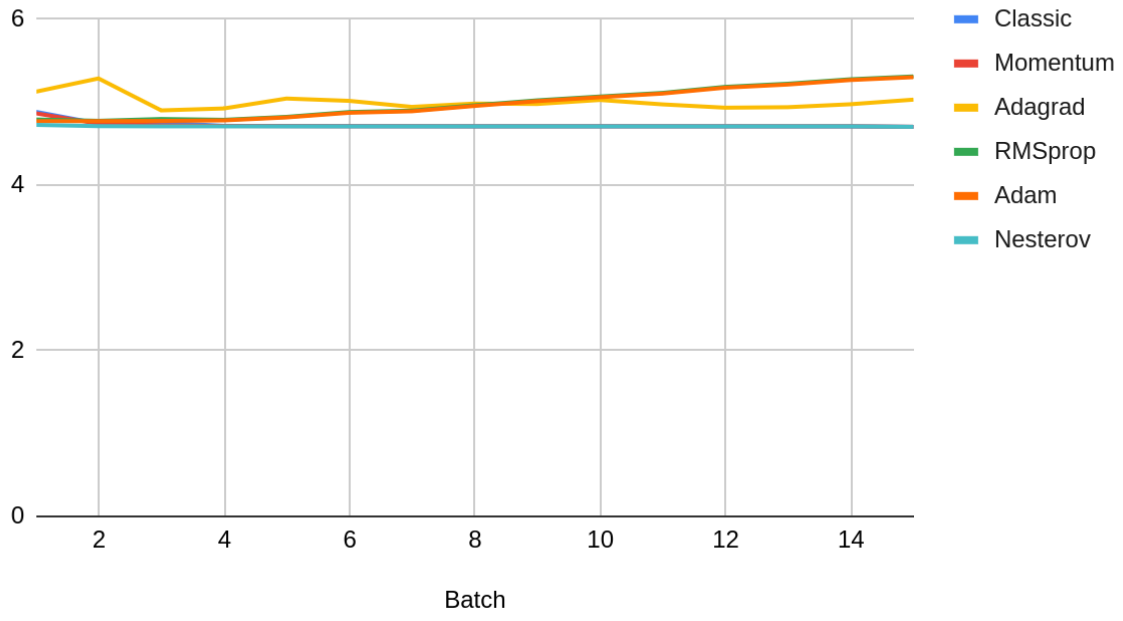

Отклонение от батча, экспоненциальная функция изменения шага

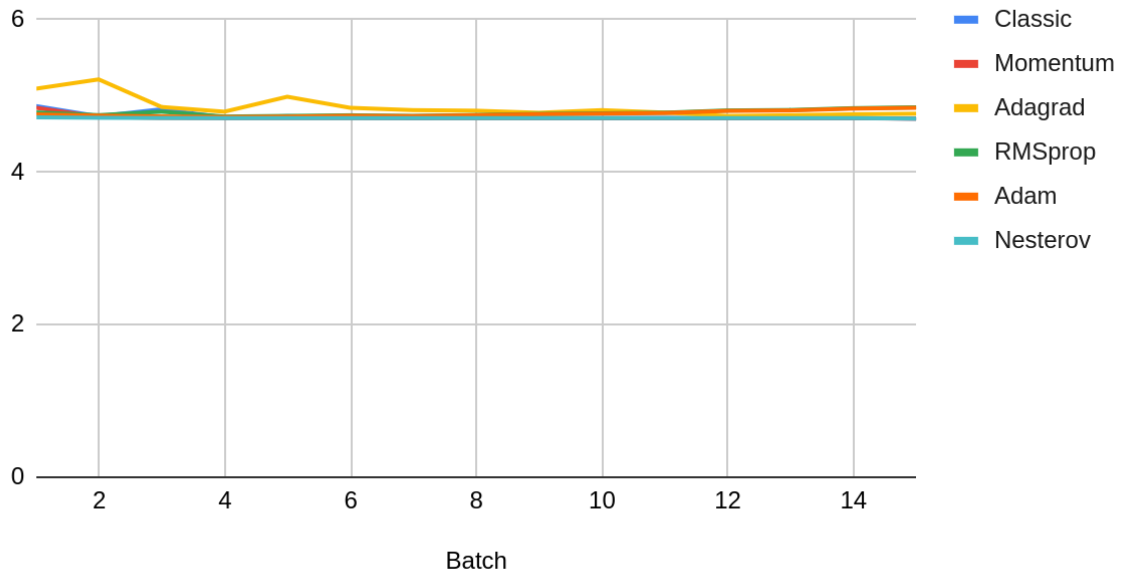

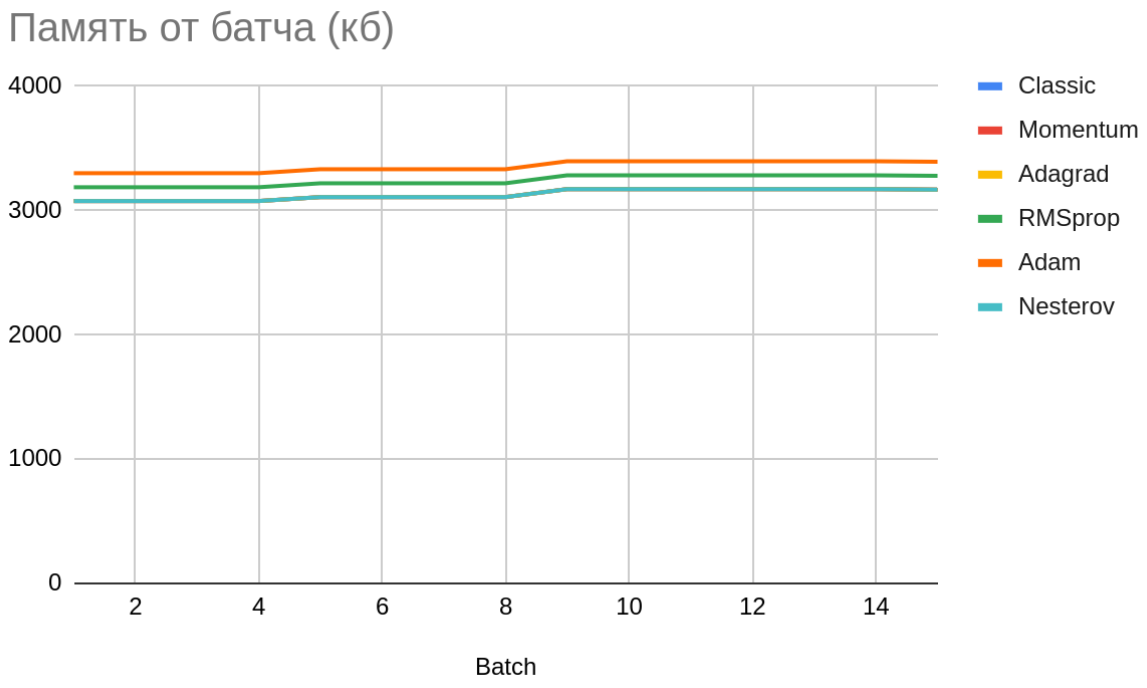
Память от батча (кб)
4000
3000
2000
1000
0
2
4
6
8
10
12
14
Batch
Classic
Momentum
Adagrad
RMSprop
Adam
Nesterov

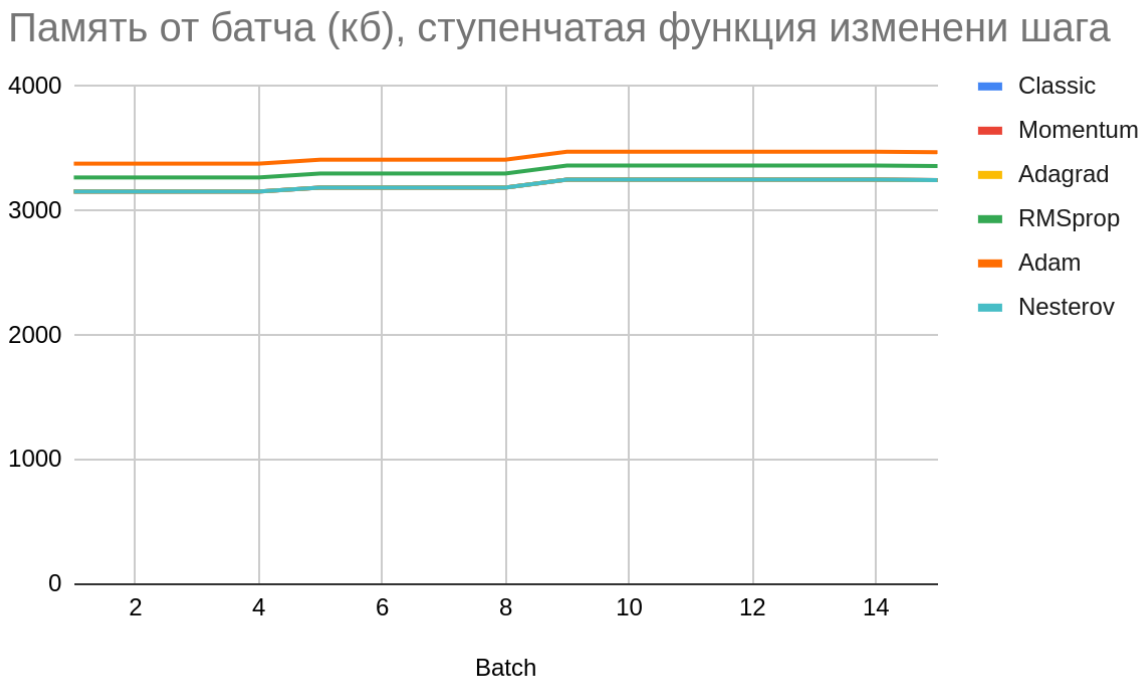
Память от батча (кб), ступенчатая функция изменени шага
4000
3000
2000
1000
0
2
4
6
8
10
12
14
Batch
Classic
Momentum
Adagrad
RMSprop
Adam
Nesterov

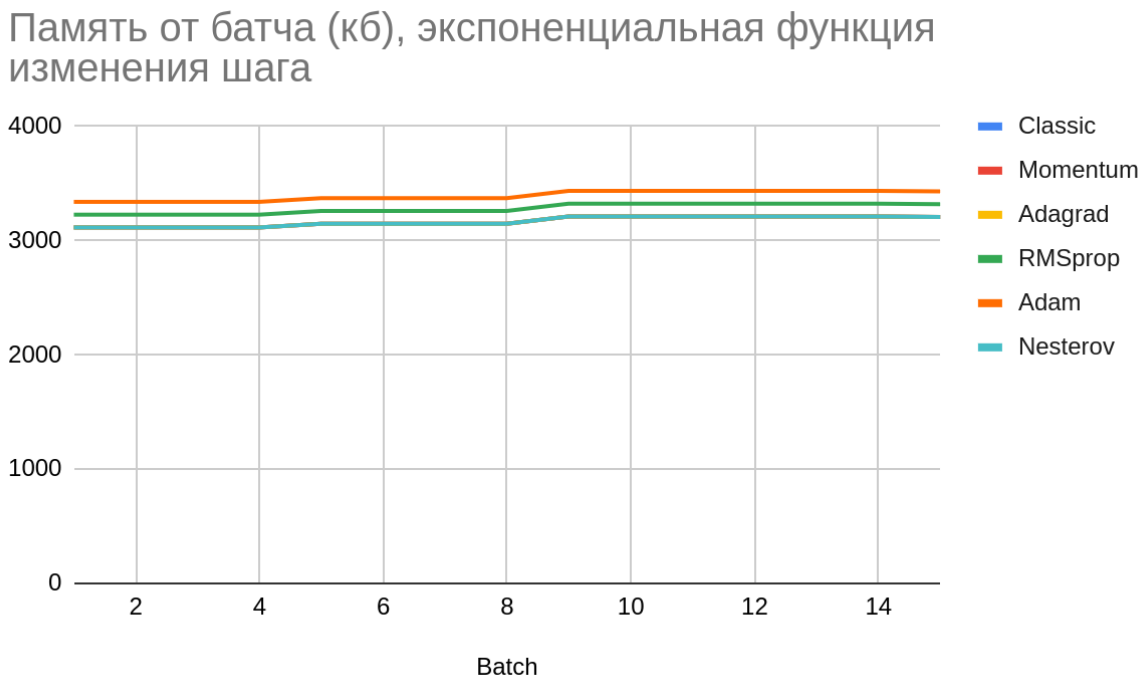

Задание №5

Примеры траекторий решения модификациями линейной регрессией

Classic 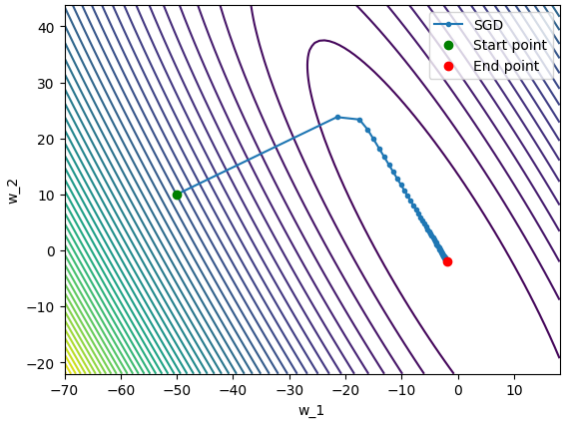	*Momentum* 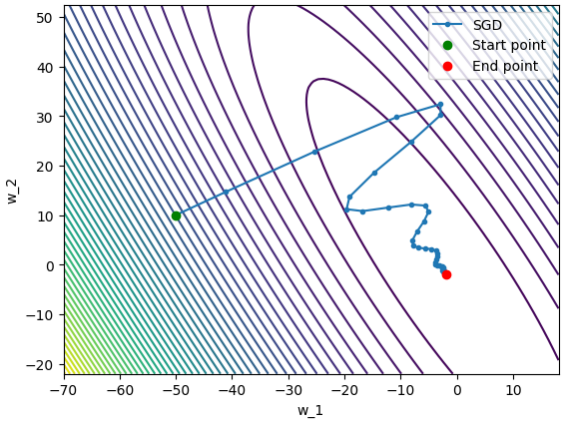
AdaGrad	*RMSprop*

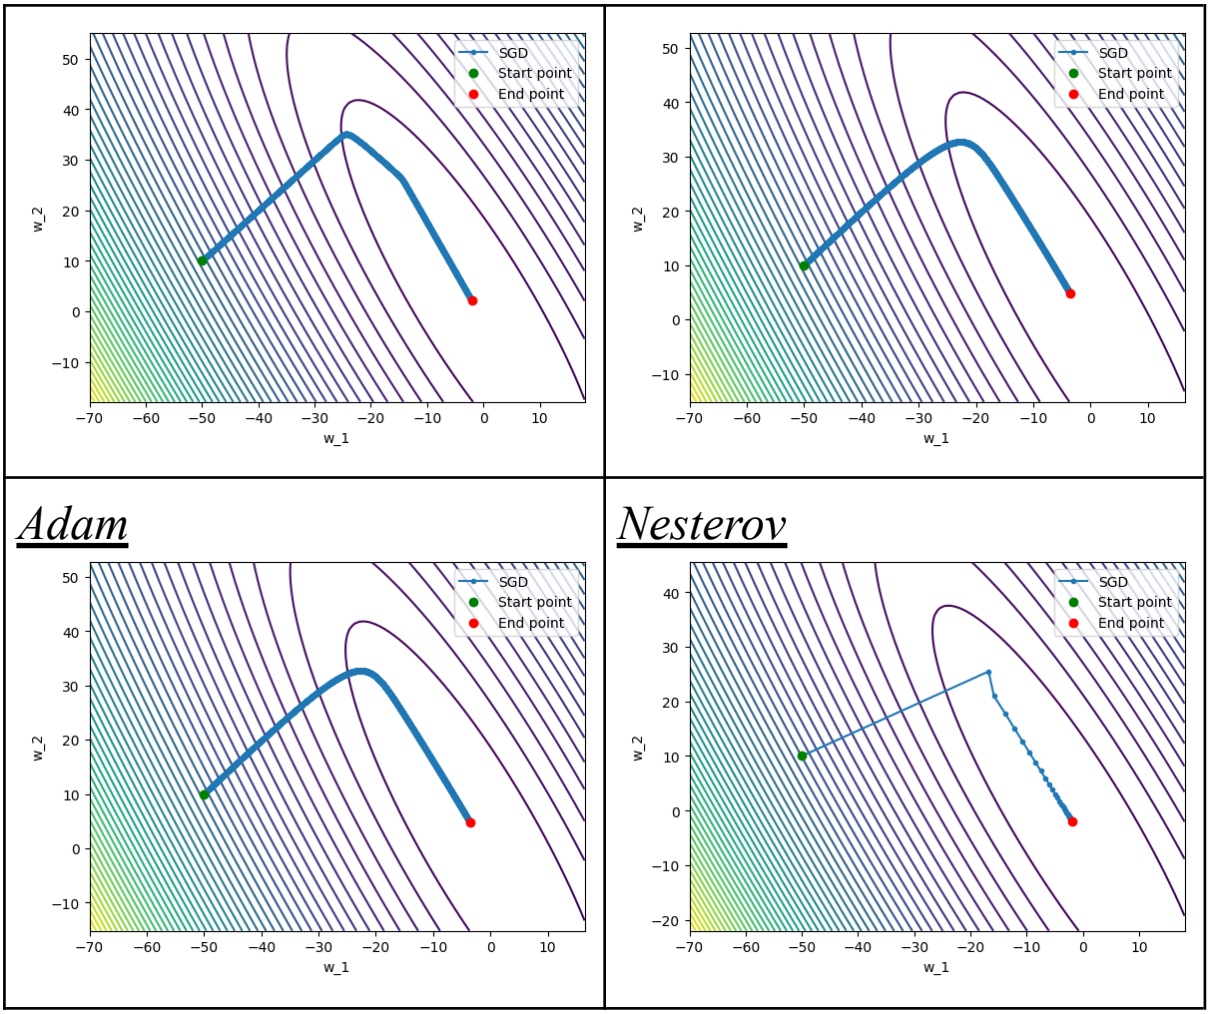

Задание №6

Регуляризация линейной регрессии - метод добавления штрафов к функции ошибки за сложность модели с целью предотвратить переобучение.

Виды	L1	L2	Elastic
Штрафы	$f_r = \frac{\lambda}{\lvert W\rvert}\sum_{i=1}^{\lvert W\rvert}\lvert w_i\rvert$	$f_r = \frac{\lambda}{\lvert W\rvert}\sum_{i=1}^{\lvert W\rvert} w_i^2$	$f_r = \frac{\lambda_1}{\lvert W\rvert}\sum_{i=1}^{\lvert W\rvert}\lvert w_i\rvert + \frac{\lambda_2}{\lvert W\rvert}\sum_{i=1}^{\lvert W\rvert} w_i^2$
Описание	Данный вид регуляризации позволяет	Минимизация регуляризованной	Приведенная регуляризация использует как L1, так и L2

	ограничить значения весов. Однако, к тому же он обладает интересным и полезным на практике свойством — обнуляет значения некоторых весов, что в случае с линейными моделями приводит к отбору признаков.	соответствующим образом функции ошибки приводит к выбору таких весов, которые не слишком сильно отклоняется от нуля. Это позволяет избежать проблем мультиколлинеарности и переобучения.	регуляризации, учитывая эффективность обоих методов. Ее полезной особенностью является то, что она создает условия для группового эффекта при высокой корреляции переменных, а не обнуляет некоторые из них, как в случае с L1 регуляризацией.

Функция ошибки линейной регрессией с регуляризацией: $\tilde{f} = f + f_r$.

1-я степень:

Тип метода	Общая информация	Функция ошибки	График
Classic	batch = 30 число точек = 100 изначальная функция = $-2x + 2$	0.00732369616724 2615	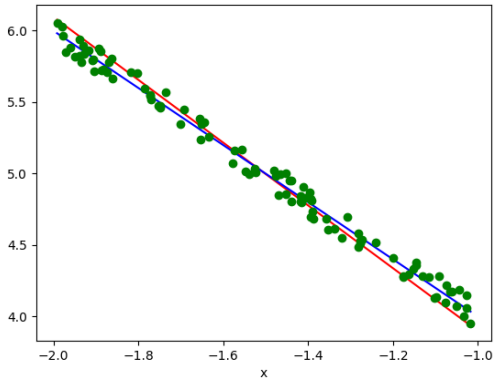

Momentum		0.00584544936416645	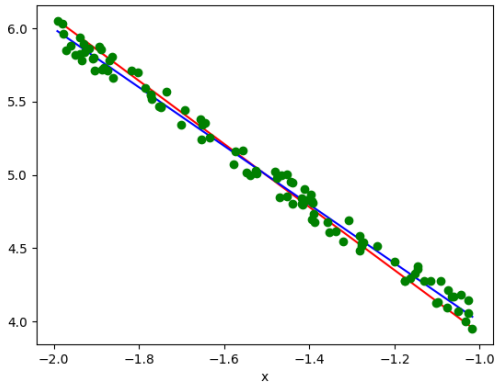
AdaGrad		0.00387144505525 7046	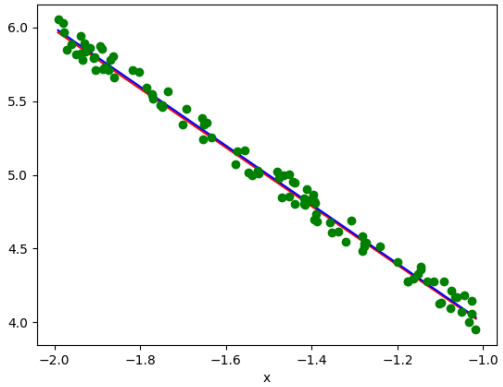
RMSProp		0.00473536679698 8567	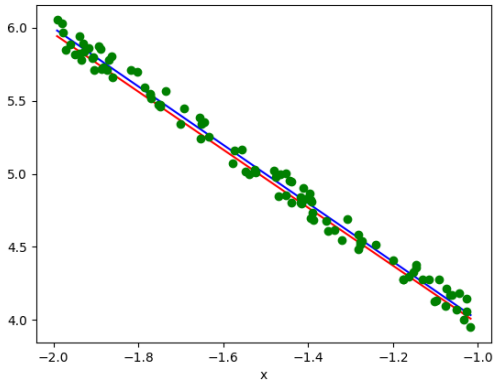

Adam		0.00429168054994464	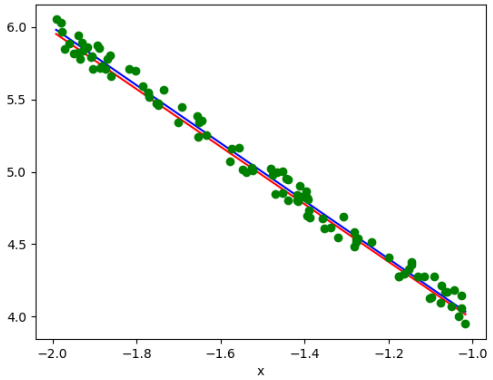
Nesterov		0.00416082514546 3381	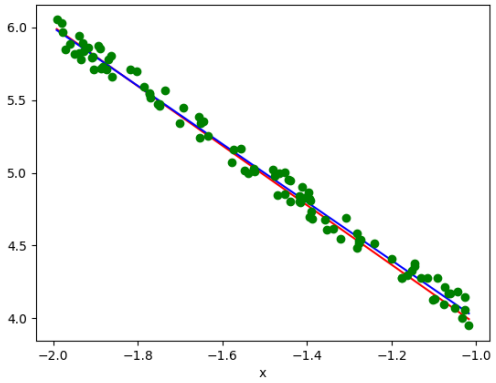

2-я степень:

Тип метода	Общая информация	Функция ошибки	График
Classic	batch = 10 число точек = 100 изначальная функция = $-3x^2 + 2x - 1$	0.0044936541207839 19	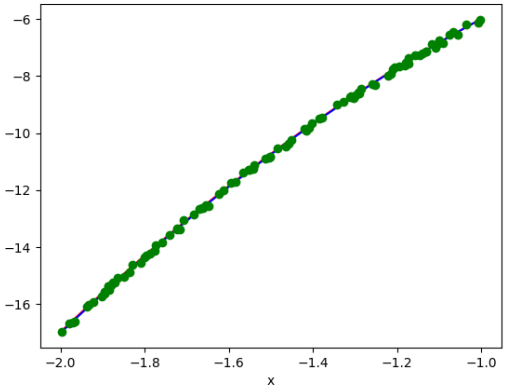

Momentum		0.0041217620797389 98	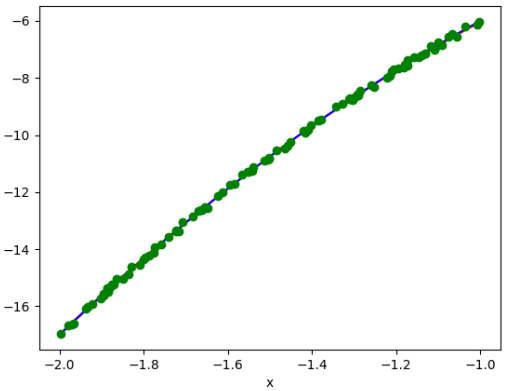
AdaGrad		0.0144994048578414 51	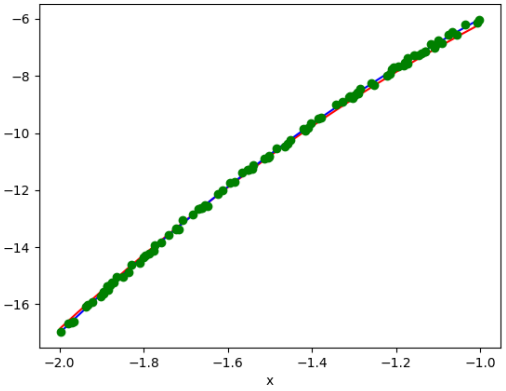
RMSProp		0.2572063750277151	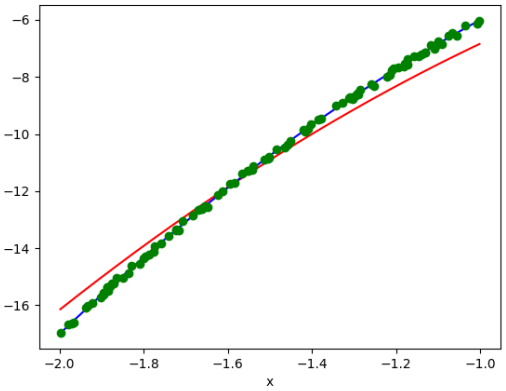

Adam		0.008394000837352207	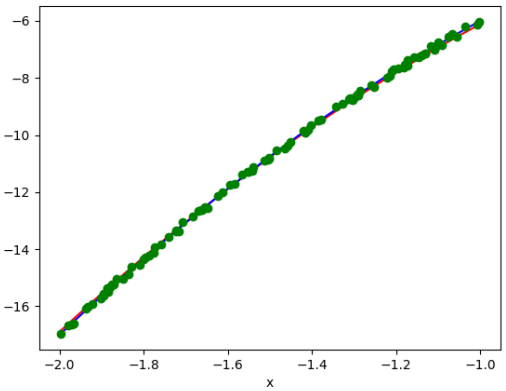
Nesterov		0.003786002586804044	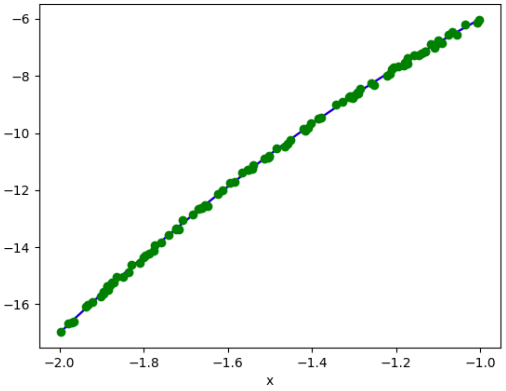

3-я степень:

Тип метода	Общая информация	Функция ошибки	График
Classic	batch = 5 число точек = 100 изначальная функция = $-3x^3 + 2x^2 + + 3x + 1$	0.006594256129393269	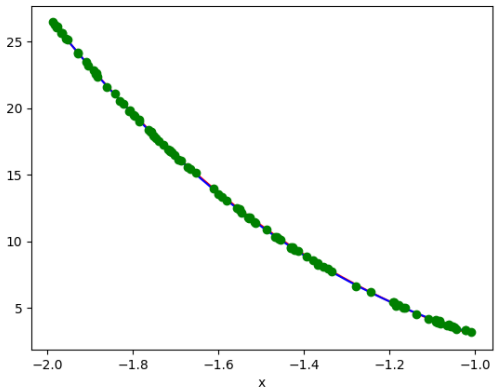

Momentum		0.007843641922304434	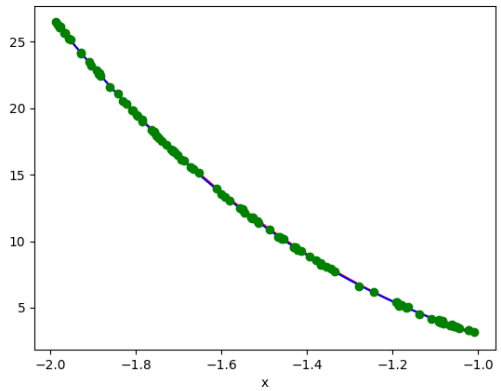
AdaGrad		0.0919475579993778 4	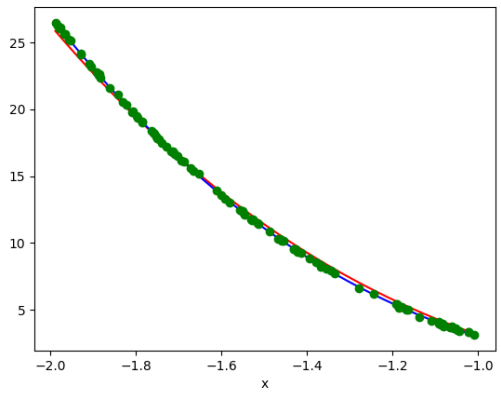
RMSProp		0.1532370586300841 6	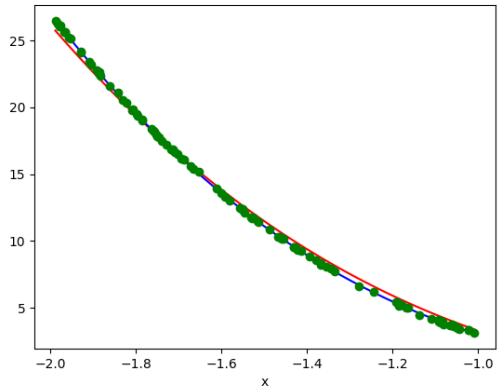

Adam		0.0262215058142555 72	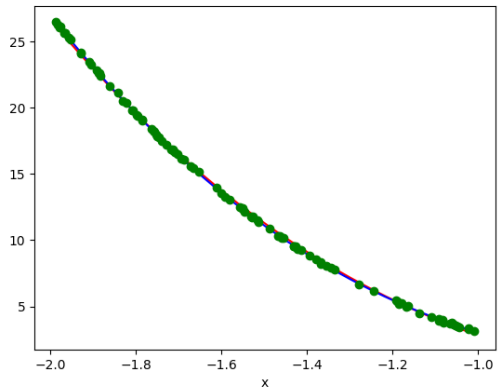
Nesterov		0.0068141972276030 87	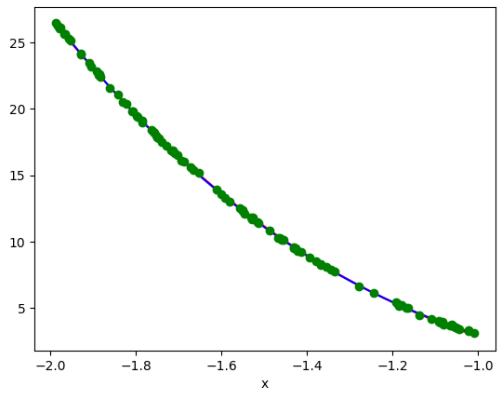

Задание №7

Примеры решения линейной регрессии с регуляризацией:

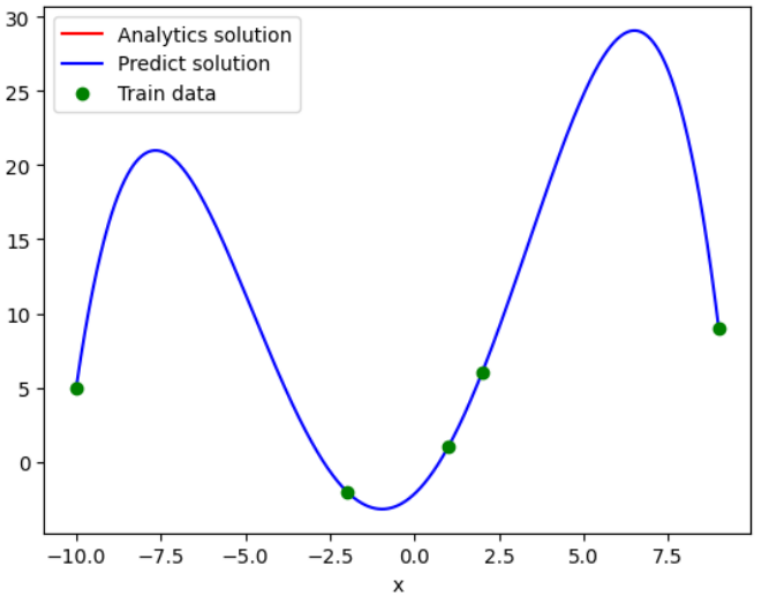

Без регуляризации

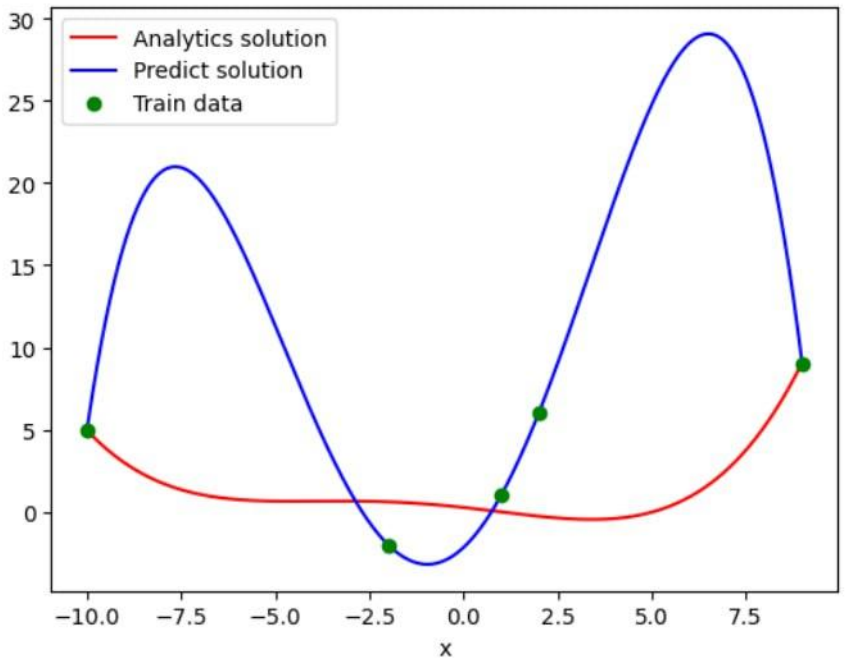

Elastic и L2

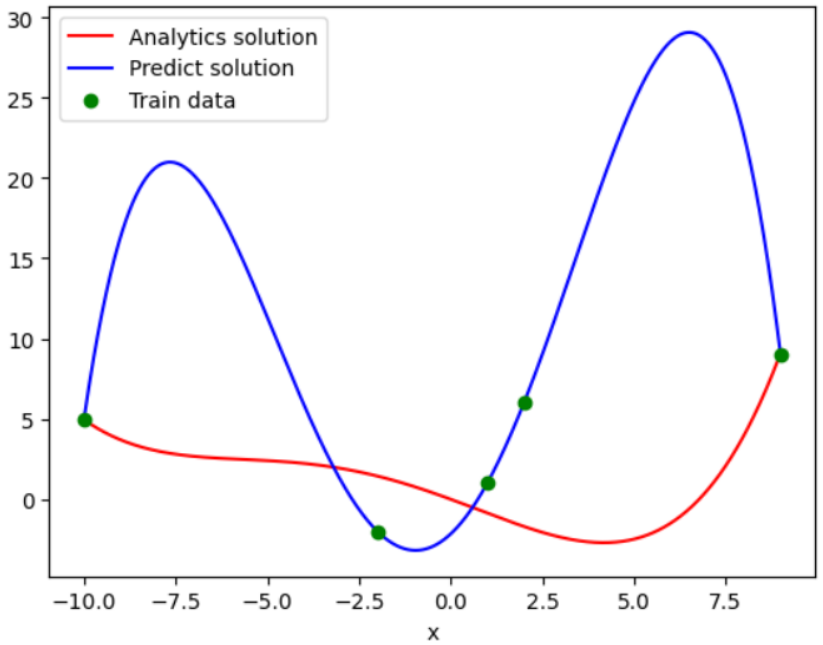

L1